# 实验二： 使用SARSA、Q-learning解决悬崖寻路问题

**姓名：**

刘乐

**学号：**

26120258

## 实验目的

- 分别利用 SARSA 算法和 Q-learning 算法寻找悬崖寻路问题中的最优策略；
- 掌握 SARSA、Q-learning 算法的区别及其核心环节。

## 1. SARSA、Q-learning 算法流程

### Sarsa: An on-policy TD control algorithm

**Sarsa (on-policy TD control) for estimating $Q \approx q_*$**

Initialize $Q(s,a)$, for all $s \in \mathcal{S}, a \in \mathcal{A}(s)$, arbitrarily, and $Q(\textit{terminal-state},\cdot) = 0$
Repeat (for each episode):
  Initialize $S$
  Choose $A$ from $S$ using policy derived from $Q$ (e.g., $\epsilon$-greedy)
  Repeat (for each step of episode):
    Take action $A$, observe $R$, $S'$
    Choose $A'$ from $S'$ using policy derived from $Q$ (e.g., $\epsilon$-greedy)
    $Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma Q(S',A') - Q(S,A)\big]$
    $S \leftarrow S'$; $A \leftarrow A'$;
  until $S$ is terminal

### Q-learning: An off-policy TD control algorithm

**Q-learning (off-policy TD control) for estimating $\pi \approx \pi_*$**

Initialize $Q(s,a)$, for all $s \in \mathcal{S}, a \in \mathcal{A}(s)$, arbitrarily, and $Q(\textit{terminal-state},\cdot) = 0$
Repeat (for each episode):
  Initialize $S$
  Repeat (for each step of episode):
    Choose $A$ from $S$ using policy derived from $Q$ (e.g., $\epsilon$-greedy)
    Take action $A$, observe $R$, $S'$
    $Q(S,A) \leftarrow Q(S,A) + \alpha\big[R + \gamma \max_a Q(S',a) - Q(S,A)\big]$
    $S \leftarrow S'$
  until $S$ is terminal

## 2. 环境介绍

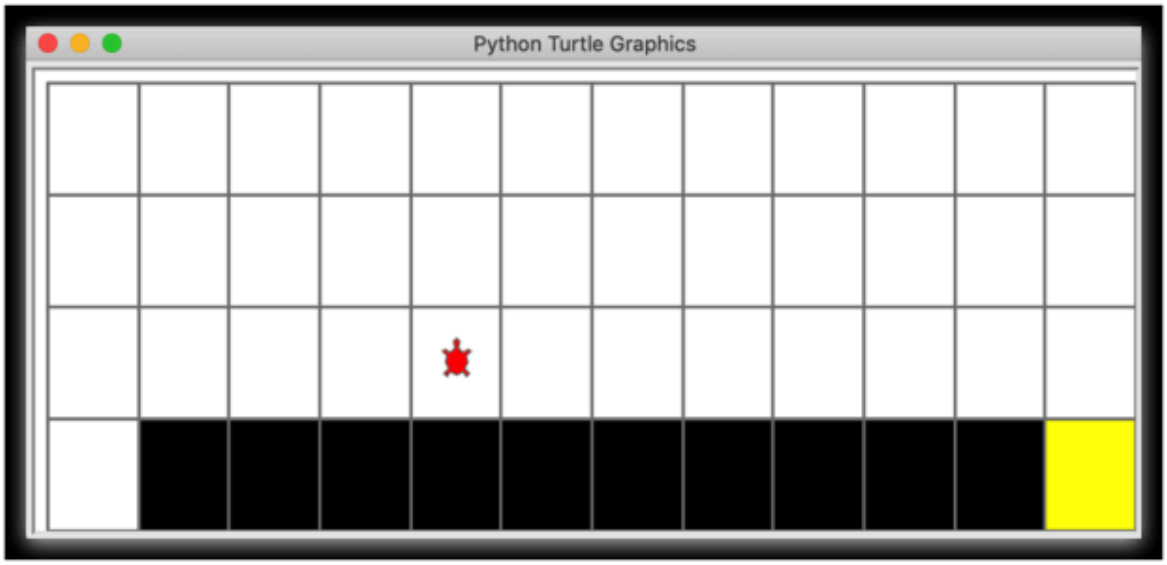
该环境名叫悬崖寻路问题，是指在一个4 x 12的网格中，智能体以网格的左下角位置为起点，以网格的下角位置为终点，目标是移动智能体到达终点位置，智能体每次可以在上、下、左、右这4个方向中移动一步，每移动一步会得到-1单位的奖励。




如图，红色部分表示悬崖，数字代表智能体能够观测到的位置信息，即observation，总共会有0-47等48个不同的值，智能体再移动中会有以下限制：

- 智能体不能移出网格，如果智能体想执行某个动作移出网格，那么这一步智能体不会移动，但是这个操作依然会得到-1单位的奖励
- 如果智能体“掉入悬崖”，会立即回到起点位置，并得到-100单位的奖励
- 当智能体移动到终点时，该回合结束，该回合总奖励为各步奖励之和

实际的仿真界面如下：




由于从起点到终点最少需要**13**步，每步得到 **-1** 的reward，因此最佳训练算法下，每个episode下reward总和应该为 **-13**。所以我们的目标也是要通过RL训练出一个模型，使得该模型能在测试中一个episode的reward能够接近于 **-13** 左右。

# 3. RL任务训练

## 3.1 本次实验所需要引入的包

In [41]:
```
import numpy as np
import math
import torch
from collections import defaultdict
import gymnasium as gym
import turtle
import argparse
import matplotlib.pyplot as plt
import seaborn as sns
```

如果缺少哪个，直接用以下命令安装即可

```
pip install (缺失包的名称)
```

## 3.2. 环境创建初始化

In [42]:
```
class CliffWalkingWapper(gym.Wrapper):
    def __init__(self, env):
        gym.Wrapper.__init__(self, env)
        self.t = None
        self.unit = 50
        self.max_x = 12
        self.max_y = 4

    def draw_x_line(self, y, x0, x1, color='gray'):
        assert x1 > x0
        self.t.color(color)
        self.t.setheading(0)
        self.t.up()
        self.t.goto(x0, y)
        self.t.down()
        self.t.forward(x1 - x0)

    def draw_y_line(self, x, y0, y1, color='gray'):
        assert y1 > y0
        self.t.color(color)
        self.t.setheading(90)
        self.t.up()
        self.t.goto(x, y0)
        self.t.down()
        self.t.forward(y1 - y0)

    def draw_box(self, x, y, fillcolor='', line_color='gray'):
        self.t.up()
        self.t.goto(x * self.unit, y * self.unit)
        self.t.color(line_color)
        self.t.fillcolor(fillcolor)
        self.t.setheading(90)
        self.t.down()
        self.t.begin_fill()
        for i in range(4):
            self.t.forward(self.unit)
            self.t.right(90)
        self.t.end_fill()

    def move_player(self, x, y):
        self.t.up()
        self.t.setheading(90)
        self.t.fillcolor('red')
        self.t.goto((x + 0.5) * self.unit, (y + 0.5) * self.unit)

    def render(self):
        if self.t == None:
            self.t = turtle.Turtle()
            self.wn = turtle.Screen()
            self.wn.setup(self.unit * self.max_x + 100,
                          self.unit * self.max_y + 100)
            self.wn.setworldcoordinates(0, 0, self.unit * self.max_x,
```

```
                                        self.unit * self.max_y)
            self.t.shape('circle')
            self.t.width(2)
            self.t.speed(0)
            self.t.color('gray')
            for _ in range(2):
                self.t.forward(self.max_x * self.unit)
                self.t.left(90)
                self.t.forward(self.max_y * self.unit)
                self.t.left(90)
            for i in range(1, self.max_y):
                self.draw_x_line(
                    y=i * self.unit, x0=0, x1=self.max_x * self.unit)
            for i in range(1, self.max_x):
                self.draw_y_line(
                    x=i * self.unit, y0=0, y1=self.max_y * self.unit)

            for i in range(1, self.max_x - 1):
                self.draw_box(i, 0, 'black')
            self.draw_box(self.max_x - 1, 0, 'yellow')
            self.t.shape('turtle')

        x_pos = self.unwrapped.s % self.max_x
        y_pos = self.max_y - 1 - int(self.unwrapped.s / self.max_x)
        self.move_player(x_pos, y_pos)
```

## 3.3 画出结果曲线所需要的工具定义

In [43]:

```
def smooth(data, weight=0.9):
    '''用于平滑曲线，类似于Tensorboard中的smooth

    Args:
        data (List):输入数据
        weight (Float): 平滑权重，处于0-1之间，数值越高说明越平滑，一般取0.9

    Returns:
        smoothed (List): 平滑后的数据
    '''
    last = data[0]  # First value in the plot (first timestep)
    smoothed = list()
    for point in data:
        smoothed_val = last * weight + (1 - weight) * point  # 计算平滑值
        smoothed.append(smoothed_val)
        last = smoothed_val
    return smoothed

def plot_rewards(rewards,cfg, tag='train'):
    sns.set()
    plt.figure()  # 创建一个图形实例，方便同时多画几个图
    plt.title("learning curve on {} of {} for {}".format(
        cfg.device, cfg.algo_name, cfg.env_name))
    plt.xlabel('epsiodes')
    plt.plot(rewards, label='rewards')
    plt.plot(smooth(rewards), label='smoothed')
    plt.legend()
    plt.show()
```

# 3.4 SARSA

## 3.4.1 相关参数设定

In [44]:

```
parser = argparse.ArgumentParser(description="hyperparameters")
parser.add_argument('--algo_name',default='Sarsa',type=str,help="name of algorithm")# 算法名称
parser.add_argument('--env_name',default='CliffWalking-v1',type=str,help="name of environment")
parser.add_argument('--train_eps',default=400,type=int,help="episodes of training") # 训练的回合数
parser.add_argument('--test_eps',default=20,type=int,help="episodes of testing") # 测试的回合数
parser.add_argument('--gamma',default=0.90,type=float,help="discounted factor") # 折扣因子
parser.add_argument('--epsilon',default=0.3,type=float,help="initial value of epsilon") #  e-greedy策略中初始epsilon
parser.add_argument('--lr',default=0.1,type=float,help="learning rate")
parser.add_argument('--device',default='cpu',type=str,help="cpu or cuda")
parser.add_argument('--seed',default=26120258,type=int,help="random seed")
cfg = parser.parse_args([])
```

### 3.4.2 SARSA 主要代码框架

In [45]:
```
class Sarsa(object):
    def __init__(self,
                 n_actions,cfg):
        self.n_actions = n_actions
        self.lr = cfg.lr
        self.gamma = cfg.gamma
        self.sample_count = 0
        self.epsilon = cfg.epsilon
        self.Q  = defaultdict(lambda: np.zeros(n_actions)) # Q table
    def sample(self, state):
        self.sample_count += 1
        best_action = np.argmax(self.Q[state])
        action_probs = np.ones(self.n_actions, dtype=float) * self.epsilon / self.n_actions
        action_probs[best_action] += (1.0 - self.epsilon)
        action = np.random.choice(np.arange(len(action_probs)), p=action_probs)
        return action
    def predict(self,state):
        return np.argmax(self.Q[state])
    def update(self, state, action, reward, next_state, next_action,done):
        Q_predict = self.Q[state][action]  # 获得当前预测Q值
        if done:
            Q_target = reward  # 终止状态不再考虑未来奖励
        else:
            #与 Q-learning不同，Sarsa是拿下一步动作对应的Q值去更新
            Q_target = reward + self.gamma * self.Q[next_state][next_action]

        self.Q[state][action] += self.lr * (Q_target - Q_predict)
```

In [46]:
```
def env_agent_config(cfg,seed=1):
    '''创建环境和智能体
    Args:
        cfg ([type]): [description]
        seed (int, optional): 随机种子. Defaults to 1.
    Returns:
        env [type]: 环境
        agent : 智能体
    '''
    seed = cfg.seed
    np.random.seed(seed)

    env = gym.make(cfg.env_name)
    env = CliffWalkingWapper(env)
    env.reset(seed=seed) # 设置随机种子并初始化环境
    n_states = env.observation_space.n # 状态维度
    n_actions = env.action_space.n # 动作维度
    print(f"状态数：{n_states}，动作数：{n_actions}")
    agent = Sarsa(n_actions,cfg)
    return env,agent
```

In [47]:
```
env, agent = env_agent_config(cfg)
```

状态数：48，动作数：4

### 3.4.3 开始训练

In [48]:
```
print('开始训练！')
print(f'环境:{cfg.env_name}, 算法:{cfg.algo_name}, 设备:{cfg.device}')
train_rewards = []  # 记录奖励
for i_ep in range(cfg.train_eps):
    ep_reward = 0  # 记录每个回合的奖励
    state, _ = env.reset()  # 重置环境,即开始新的回合
    action = agent.sample(state)
    while True:
        next_state, reward, terminated, truncated, _ = env.step(action)
        done = terminated or truncated  # 到达终点或回合被截断时结束
        next_action = agent.sample(next_state)
        agent.update(state, action, reward, next_state, next_action, terminated) # 算法更新
        state = next_state # 更新状态
        action = next_action
        ep_reward += reward
        if done:
```

```
            break
    train_rewards.append(ep_reward)
    print(f"回合：{i_ep+1}/{cfg.train_eps}，奖励：{ep_reward:.1f}，Epsilon：{agent.epsilon}")
print('完成训练！')
```

```
开始训练!
环境:CliffWalking-v1, 算法:Sarsa, 设备:cpu
回合：1/400，奖励：-2139.0，Epsilon：0.3
回合：2/400，奖励：-2260.0，Epsilon：0.3
回合：3/400，奖励：-605.0，Epsilon：0.3
回合：4/400，奖励：-817.0，Epsilon：0.3
回合：5/400，奖励：-153.0，Epsilon：0.3
回合：6/400，奖励：-57.0，Epsilon：0.3
回合：7/400，奖励：-318.0，Epsilon：0.3
回合：8/400，奖励：-842.0，Epsilon：0.3
回合：9/400，奖励：-109.0，Epsilon：0.3
回合：10/400，奖励：-621.0，Epsilon：0.3
回合：11/400，奖励：-67.0，Epsilon：0.3
回合：12/400，奖励：-151.0，Epsilon：0.3
回合：13/400，奖励：-85.0，Epsilon：0.3
回合：14/400，奖励：-600.0，Epsilon：0.3
回合：15/400，奖励：-118.0，Epsilon：0.3
回合：16/400，奖励：-163.0，Epsilon：0.3
回合：17/400，奖励：-96.0，Epsilon：0.3
回合：18/400，奖励：-200.0，Epsilon：0.3
回合：19/400，奖励：-43.0，Epsilon：0.3
回合：20/400，奖励：-406.0，Epsilon：0.3
回合：21/400，奖励：-103.0，Epsilon：0.3
回合：22/400，奖励：-78.0，Epsilon：0.3
回合：23/400，奖励：-94.0，Epsilon：0.3
回合：24/400，奖励：-149.0，Epsilon：0.3
回合：25/400，奖励：-77.0，Epsilon：0.3
回合：26/400，奖励：-476.0，Epsilon：0.3
回合：27/400，奖励：-184.0，Epsilon：0.3
回合：28/400，奖励：-41.0，Epsilon：0.3
回合：29/400，奖励：-380.0，Epsilon：0.3
回合：30/400，奖励：-43.0，Epsilon：0.3
回合：31/400，奖励：-62.0，Epsilon：0.3
回合：32/400，奖励：-434.0，Epsilon：0.3
回合：33/400，奖励：-265.0，Epsilon：0.3
回合：34/400，奖励：-149.0，Epsilon：0.3
回合：35/400，奖励：-62.0，Epsilon：0.3
回合：36/400，奖励：-51.0，Epsilon：0.3
回合：37/400，奖励：-74.0，Epsilon：0.3
回合：38/400，奖励：-39.0，Epsilon：0.3
回合：39/400，奖励：-78.0，Epsilon：0.3
回合：40/400，奖励：-71.0，Epsilon：0.3
回合：41/400，奖励：-50.0，Epsilon：0.3
回合：42/400，奖励：-109.0，Epsilon：0.3
回合：43/400，奖励：-239.0，Epsilon：0.3
回合：44/400，奖励：-363.0，Epsilon：0.3
回合：45/400，奖励：-45.0，Epsilon：0.3
回合：46/400，奖励：-134.0，Epsilon：0.3
回合：47/400，奖励：-49.0，Epsilon：0.3
回合：48/400，奖励：-179.0，Epsilon：0.3
回合：49/400，奖励：-137.0，Epsilon：0.3
回合：50/400，奖励：-146.0，Epsilon：0.3
回合：51/400，奖励：-38.0，Epsilon：0.3
回合：52/400，奖励：-183.0，Epsilon：0.3
回合：53/400，奖励：-66.0，Epsilon：0.3
回合：54/400，奖励：-52.0，Epsilon：0.3
回合：55/400，奖励：-43.0，Epsilon：0.3
回合：56/400，奖励：-57.0，Epsilon：0.3
回合：57/400，奖励：-30.0，Epsilon：0.3
回合：58/400，奖励：-36.0，Epsilon：0.3
回合：59/400，奖励：-306.0，Epsilon：0.3
回合：60/400，奖励：-32.0，Epsilon：0.3
回合：61/400，奖励：-41.0，Epsilon：0.3
回合：62/400，奖励：-40.0，Epsilon：0.3
回合：63/400，奖励：-90.0，Epsilon：0.3
回合：64/400，奖励：-28.0，Epsilon：0.3
回合：65/400，奖励：-172.0，Epsilon：0.3
回合：66/400，奖励：-42.0，Epsilon：0.3
回合：67/400，奖励：-46.0，Epsilon：0.3
回合：68/400，奖励：-66.0，Epsilon：0.3
```

回合: 69/400, 奖励: -42.0, Epsilon: 0.3
回合: 70/400, 奖励: -175.0, Epsilon: 0.3
回合: 71/400, 奖励: -94.0, Epsilon: 0.3
回合: 72/400, 奖励: -31.0, Epsilon: 0.3
回合: 73/400, 奖励: -21.0, Epsilon: 0.3
回合: 74/400, 奖励: -27.0, Epsilon: 0.3
回合: 75/400, 奖励: -36.0, Epsilon: 0.3
回合: 76/400, 奖励: -275.0, Epsilon: 0.3
回合: 77/400, 奖励: -44.0, Epsilon: 0.3
回合: 78/400, 奖励: -308.0, Epsilon: 0.3
回合: 79/400, 奖励: -308.0, Epsilon: 0.3
回合: 80/400, 奖励: -33.0, Epsilon: 0.3
回合: 81/400, 奖励: -39.0, Epsilon: 0.3
回合: 82/400, 奖励: -389.0, Epsilon: 0.3
回合: 83/400, 奖励: -146.0, Epsilon: 0.3
回合: 84/400, 奖励: -37.0, Epsilon: 0.3
回合: 85/400, 奖励: -27.0, Epsilon: 0.3
回合: 86/400, 奖励: -129.0, Epsilon: 0.3
回合: 87/400, 奖励: -57.0, Epsilon: 0.3
回合: 88/400, 奖励: -36.0, Epsilon: 0.3
回合: 89/400, 奖励: -25.0, Epsilon: 0.3
回合: 90/400, 奖励: -36.0, Epsilon: 0.3
回合: 91/400, 奖励: -52.0, Epsilon: 0.3
回合: 92/400, 奖励: -163.0, Epsilon: 0.3
回合: 93/400, 奖励: -222.0, Epsilon: 0.3
回合: 94/400, 奖励: -45.0, Epsilon: 0.3
回合: 95/400, 奖励: -36.0, Epsilon: 0.3
回合: 96/400, 奖励: -68.0, Epsilon: 0.3
回合: 97/400, 奖励: -35.0, Epsilon: 0.3
回合: 98/400, 奖励: -25.0, Epsilon: 0.3
回合: 99/400, 奖励: -71.0, Epsilon: 0.3
回合: 100/400, 奖励: -152.0, Epsilon: 0.3
回合: 101/400, 奖励: -32.0, Epsilon: 0.3
回合: 102/400, 奖励: -152.0, Epsilon: 0.3
回合: 103/400, 奖励: -46.0, Epsilon: 0.3
回合: 104/400, 奖励: -51.0, Epsilon: 0.3
回合: 105/400, 奖励: -37.0, Epsilon: 0.3
回合: 106/400, 奖励: -141.0, Epsilon: 0.3
回合: 107/400, 奖励: -30.0, Epsilon: 0.3
回合: 108/400, 奖励: -25.0, Epsilon: 0.3
回合: 109/400, 奖励: -58.0, Epsilon: 0.3
回合: 110/400, 奖励: -28.0, Epsilon: 0.3
回合: 111/400, 奖励: -35.0, Epsilon: 0.3
回合: 112/400, 奖励: -27.0, Epsilon: 0.3
回合: 113/400, 奖励: -26.0, Epsilon: 0.3
回合: 114/400, 奖励: -39.0, Epsilon: 0.3
回合: 115/400, 奖励: -136.0, Epsilon: 0.3
回合: 116/400, 奖励: -33.0, Epsilon: 0.3
回合: 117/400, 奖励: -168.0, Epsilon: 0.3
回合: 118/400, 奖励: -26.0, Epsilon: 0.3
回合: 119/400, 奖励: -32.0, Epsilon: 0.3
回合: 120/400, 奖励: -31.0, Epsilon: 0.3
回合: 121/400, 奖励: -43.0, Epsilon: 0.3
回合: 122/400, 奖励: -26.0, Epsilon: 0.3
回合: 123/400, 奖励: -31.0, Epsilon: 0.3
回合: 124/400, 奖励: -57.0, Epsilon: 0.3
回合: 125/400, 奖励: -31.0, Epsilon: 0.3
回合: 126/400, 奖励: -38.0, Epsilon: 0.3
回合: 127/400, 奖励: -38.0, Epsilon: 0.3
回合: 128/400, 奖励: -36.0, Epsilon: 0.3
回合: 129/400, 奖励: -26.0, Epsilon: 0.3
回合: 130/400, 奖励: -28.0, Epsilon: 0.3
回合: 131/400, 奖励: -31.0, Epsilon: 0.3
回合: 132/400, 奖励: -43.0, Epsilon: 0.3
回合: 133/400, 奖励: -21.0, Epsilon: 0.3
回合: 134/400, 奖励: -61.0, Epsilon: 0.3
回合: 135/400, 奖励: -138.0, Epsilon: 0.3
回合: 136/400, 奖励: -30.0, Epsilon: 0.3
回合: 137/400, 奖励: -26.0, Epsilon: 0.3
回合: 138/400, 奖励: -21.0, Epsilon: 0.3
回合: 139/400, 奖励: -51.0, Epsilon: 0.3
回合: 140/400, 奖励: -22.0, Epsilon: 0.3
回合: 141/400, 奖励: -29.0, Epsilon: 0.3
回合: 142/400, 奖励: -20.0, Epsilon: 0.3
回合: 143/400, 奖励: -27.0, Epsilon: 0.3
回合: 144/400, 奖励: -23.0, Epsilon: 0.3

回合: 145/400, 奖励: -130.0, Epsilon: 0.3
回合: 146/400, 奖励: -39.0, Epsilon: 0.3
回合: 147/400, 奖励: -31.0, Epsilon: 0.3
回合: 148/400, 奖励: -166.0, Epsilon: 0.3
回合: 149/400, 奖励: -23.0, Epsilon: 0.3
回合: 150/400, 奖励: -38.0, Epsilon: 0.3
回合: 151/400, 奖励: -30.0, Epsilon: 0.3
回合: 152/400, 奖励: -28.0, Epsilon: 0.3
回合: 153/400, 奖励: -32.0, Epsilon: 0.3
回合: 154/400, 奖励: -28.0, Epsilon: 0.3
回合: 155/400, 奖励: -27.0, Epsilon: 0.3
回合: 156/400, 奖励: -122.0, Epsilon: 0.3
回合: 157/400, 奖励: -35.0, Epsilon: 0.3
回合: 158/400, 奖励: -260.0, Epsilon: 0.3
回合: 159/400, 奖励: -28.0, Epsilon: 0.3
回合: 160/400, 奖励: -23.0, Epsilon: 0.3
回合: 161/400, 奖励: -32.0, Epsilon: 0.3
回合: 162/400, 奖励: -25.0, Epsilon: 0.3
回合: 163/400, 奖励: -25.0, Epsilon: 0.3
回合: 164/400, 奖励: -19.0, Epsilon: 0.3
回合: 165/400, 奖励: -129.0, Epsilon: 0.3
回合: 166/400, 奖励: -23.0, Epsilon: 0.3
回合: 167/400, 奖励: -20.0, Epsilon: 0.3
回合: 168/400, 奖励: -24.0, Epsilon: 0.3
回合: 169/400, 奖励: -24.0, Epsilon: 0.3
回合: 170/400, 奖励: -36.0, Epsilon: 0.3
回合: 171/400, 奖励: -27.0, Epsilon: 0.3
回合: 172/400, 奖励: -22.0, Epsilon: 0.3
回合: 173/400, 奖励: -20.0, Epsilon: 0.3
回合: 174/400, 奖励: -121.0, Epsilon: 0.3
回合: 175/400, 奖励: -35.0, Epsilon: 0.3
回合: 176/400, 奖励: -23.0, Epsilon: 0.3
回合: 177/400, 奖励: -27.0, Epsilon: 0.3
回合: 178/400, 奖励: -125.0, Epsilon: 0.3
回合: 179/400, 奖励: -24.0, Epsilon: 0.3
回合: 180/400, 奖励: -24.0, Epsilon: 0.3
回合: 181/400, 奖励: -240.0, Epsilon: 0.3
回合: 182/400, 奖励: -46.0, Epsilon: 0.3
回合: 183/400, 奖励: -24.0, Epsilon: 0.3
回合: 184/400, 奖励: -27.0, Epsilon: 0.3
回合: 185/400, 奖励: -144.0, Epsilon: 0.3
回合: 186/400, 奖励: -29.0, Epsilon: 0.3
回合: 187/400, 奖励: -35.0, Epsilon: 0.3
回合: 188/400, 奖励: -139.0, Epsilon: 0.3
回合: 189/400, 奖励: -40.0, Epsilon: 0.3
回合: 190/400, 奖励: -20.0, Epsilon: 0.3
回合: 191/400, 奖励: -23.0, Epsilon: 0.3
回合: 192/400, 奖励: -29.0, Epsilon: 0.3
回合: 193/400, 奖励: -28.0, Epsilon: 0.3
回合: 194/400, 奖励: -142.0, Epsilon: 0.3
回合: 195/400, 奖励: -41.0, Epsilon: 0.3
回合: 196/400, 奖励: -157.0, Epsilon: 0.3
回合: 197/400, 奖励: -28.0, Epsilon: 0.3
回合: 198/400, 奖励: -30.0, Epsilon: 0.3
回合: 199/400, 奖励: -22.0, Epsilon: 0.3
回合: 200/400, 奖励: -27.0, Epsilon: 0.3
回合: 201/400, 奖励: -43.0, Epsilon: 0.3
回合: 202/400, 奖励: -119.0, Epsilon: 0.3
回合: 203/400, 奖励: -31.0, Epsilon: 0.3
回合: 204/400, 奖励: -41.0, Epsilon: 0.3
回合: 205/400, 奖励: -30.0, Epsilon: 0.3
回合: 206/400, 奖励: -451.0, Epsilon: 0.3
回合: 207/400, 奖励: -21.0, Epsilon: 0.3
回合: 208/400, 奖励: -24.0, Epsilon: 0.3
回合: 209/400, 奖励: -33.0, Epsilon: 0.3
回合: 210/400, 奖励: -20.0, Epsilon: 0.3
回合: 211/400, 奖励: -31.0, Epsilon: 0.3
回合: 212/400, 奖励: -20.0, Epsilon: 0.3
回合: 213/400, 奖励: -30.0, Epsilon: 0.3
回合: 214/400, 奖励: -28.0, Epsilon: 0.3
回合: 215/400, 奖励: -32.0, Epsilon: 0.3
回合: 216/400, 奖励: -26.0, Epsilon: 0.3
回合: 217/400, 奖励: -22.0, Epsilon: 0.3
回合: 218/400, 奖励: -27.0, Epsilon: 0.3
回合: 219/400, 奖励: -21.0, Epsilon: 0.3
回合: 220/400, 奖励: -150.0, Epsilon: 0.3

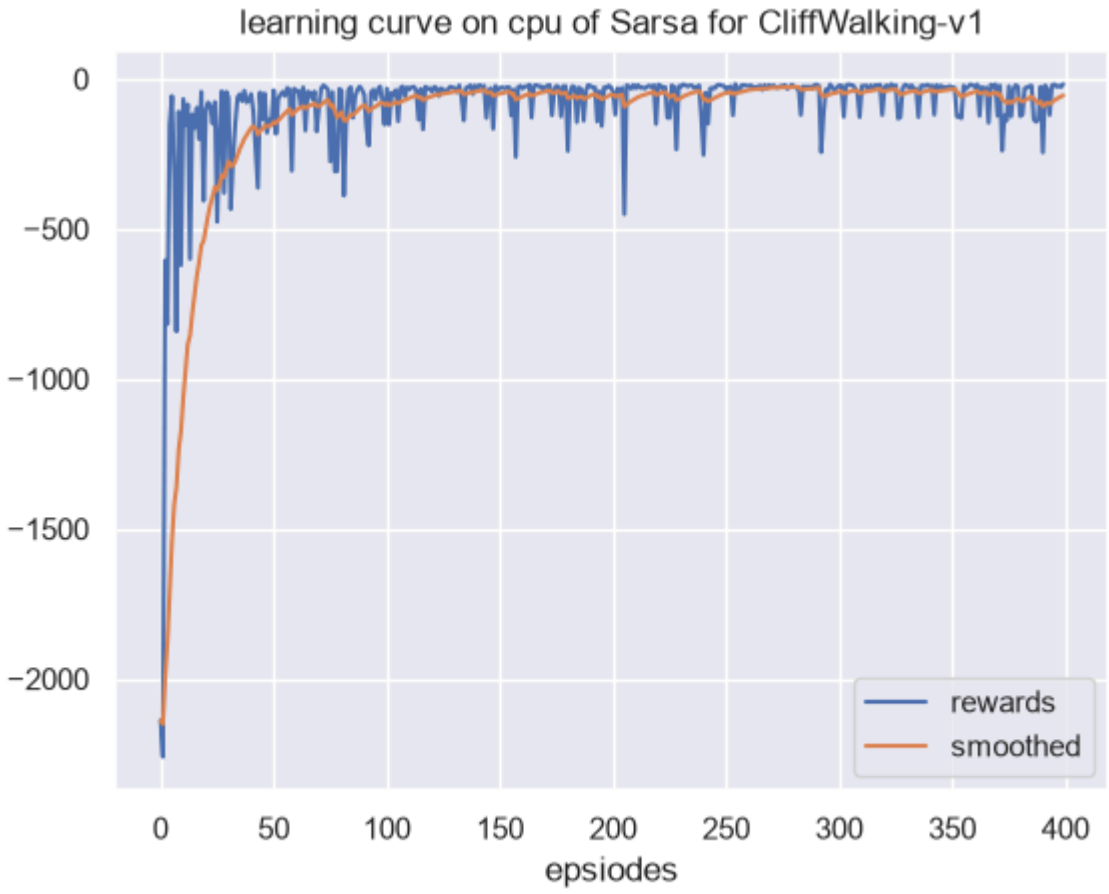
回合: 221/400, 奖励: -19.0, Epsilon: 0.3
回合: 222/400, 奖励: -22.0, Epsilon: 0.3
回合: 223/400, 奖励: -33.0, Epsilon: 0.3
回合: 224/400, 奖励: -27.0, Epsilon: 0.3
回合: 225/400, 奖励: -129.0, Epsilon: 0.3
回合: 226/400, 奖励: -130.0, Epsilon: 0.3
回合: 227/400, 奖励: -21.0, Epsilon: 0.3
回合: 228/400, 奖励: -28.0, Epsilon: 0.3
回合: 229/400, 奖励: -235.0, Epsilon: 0.3
回合: 230/400, 奖励: -24.0, Epsilon: 0.3
回合: 231/400, 奖励: -26.0, Epsilon: 0.3
回合: 232/400, 奖励: -18.0, Epsilon: 0.3
回合: 233/400, 奖励: -21.0, Epsilon: 0.3
回合: 234/400, 奖励: -25.0, Epsilon: 0.3
回合: 235/400, 奖励: -21.0, Epsilon: 0.3
回合: 236/400, 奖励: -22.0, Epsilon: 0.3
回合: 237/400, 奖励: -31.0, Epsilon: 0.3
回合: 238/400, 奖励: -28.0, Epsilon: 0.3
回合: 239/400, 奖励: -21.0, Epsilon: 0.3
回合: 240/400, 奖励: -127.0, Epsilon: 0.3
回合: 241/400, 奖励: -253.0, Epsilon: 0.3
回合: 242/400, 奖励: -46.0, Epsilon: 0.3
回合: 243/400, 奖励: -149.0, Epsilon: 0.3
回合: 244/400, 奖励: -31.0, Epsilon: 0.3
回合: 245/400, 奖励: -30.0, Epsilon: 0.3
回合: 246/400, 奖励: -31.0, Epsilon: 0.3
回合: 247/400, 奖励: -21.0, Epsilon: 0.3
回合: 248/400, 奖励: -19.0, Epsilon: 0.3
回合: 249/400, 奖励: -22.0, Epsilon: 0.3
回合: 250/400, 奖励: -23.0, Epsilon: 0.3
回合: 251/400, 奖励: -34.0, Epsilon: 0.3
回合: 252/400, 奖励: -29.0, Epsilon: 0.3
回合: 253/400, 奖励: -25.0, Epsilon: 0.3
回合: 254/400, 奖励: -121.0, Epsilon: 0.3
回合: 255/400, 奖励: -17.0, Epsilon: 0.3
回合: 256/400, 奖励: -32.0, Epsilon: 0.3
回合: 257/400, 奖励: -36.0, Epsilon: 0.3
回合: 258/400, 奖励: -20.0, Epsilon: 0.3
回合: 259/400, 奖励: -21.0, Epsilon: 0.3
回合: 260/400, 奖励: -22.0, Epsilon: 0.3
回合: 261/400, 奖励: -24.0, Epsilon: 0.3
回合: 262/400, 奖励: -21.0, Epsilon: 0.3
回合: 263/400, 奖励: -31.0, Epsilon: 0.3
回合: 264/400, 奖励: -28.0, Epsilon: 0.3
回合: 265/400, 奖励: -26.0, Epsilon: 0.3
回合: 266/400, 奖励: -22.0, Epsilon: 0.3
回合: 267/400, 奖励: -37.0, Epsilon: 0.3
回合: 268/400, 奖励: -20.0, Epsilon: 0.3
回合: 269/400, 奖励: -31.0, Epsilon: 0.3
回合: 270/400, 奖励: -20.0, Epsilon: 0.3
回合: 271/400, 奖励: -26.0, Epsilon: 0.3
回合: 272/400, 奖励: -21.0, Epsilon: 0.3
回合: 273/400, 奖励: -29.0, Epsilon: 0.3
回合: 274/400, 奖励: -29.0, Epsilon: 0.3
回合: 275/400, 奖励: -24.0, Epsilon: 0.3
回合: 276/400, 奖励: -23.0, Epsilon: 0.3
回合: 277/400, 奖励: -20.0, Epsilon: 0.3
回合: 278/400, 奖励: -33.0, Epsilon: 0.3
回合: 279/400, 奖励: -27.0, Epsilon: 0.3
回合: 280/400, 奖励: -19.0, Epsilon: 0.3
回合: 281/400, 奖励: -25.0, Epsilon: 0.3
回合: 282/400, 奖励: -30.0, Epsilon: 0.3
回合: 283/400, 奖励: -27.0, Epsilon: 0.3
回合: 284/400, 奖励: -120.0, Epsilon: 0.3
回合: 285/400, 奖励: -25.0, Epsilon: 0.3
回合: 286/400, 奖励: -26.0, Epsilon: 0.3
回合: 287/400, 奖励: -26.0, Epsilon: 0.3
回合: 288/400, 奖励: -25.0, Epsilon: 0.3
回合: 289/400, 奖励: -32.0, Epsilon: 0.3
回合: 290/400, 奖励: -20.0, Epsilon: 0.3
回合: 291/400, 奖励: -19.0, Epsilon: 0.3
回合: 292/400, 奖励: -23.0, Epsilon: 0.3
回合: 293/400, 奖励: -244.0, Epsilon: 0.3
回合: 294/400, 奖励: -120.0, Epsilon: 0.3
回合: 295/400, 奖励: -36.0, Epsilon: 0.3
回合: 296/400, 奖励: -40.0, Epsilon: 0.3

回合: 297/400, 奖励: -18.0, Epsilon: 0.3
回合: 298/400, 奖励: -30.0, Epsilon: 0.3
回合: 299/400, 奖励: -36.0, Epsilon: 0.3
回合: 300/400, 奖励: -28.0, Epsilon: 0.3
回合: 301/400, 奖励: -21.0, Epsilon: 0.3
回合: 302/400, 奖励: -22.0, Epsilon: 0.3
回合: 303/400, 奖励: -126.0, Epsilon: 0.3
回合: 304/400, 奖励: -22.0, Epsilon: 0.3
回合: 305/400, 奖励: -18.0, Epsilon: 0.3
回合: 306/400, 奖励: -20.0, Epsilon: 0.3
回合: 307/400, 奖励: -21.0, Epsilon: 0.3
回合: 308/400, 奖励: -31.0, Epsilon: 0.3
回合: 309/400, 奖励: -47.0, Epsilon: 0.3
回合: 310/400, 奖励: -127.0, Epsilon: 0.3
回合: 311/400, 奖励: -23.0, Epsilon: 0.3
回合: 312/400, 奖励: -23.0, Epsilon: 0.3
回合: 313/400, 奖励: -22.0, Epsilon: 0.3
回合: 314/400, 奖励: -36.0, Epsilon: 0.3
回合: 315/400, 奖励: -21.0, Epsilon: 0.3
回合: 316/400, 奖励: -32.0, Epsilon: 0.3
回合: 317/400, 奖励: -20.0, Epsilon: 0.3
回合: 318/400, 奖励: -22.0, Epsilon: 0.3
回合: 319/400, 奖励: -19.0, Epsilon: 0.3
回合: 320/400, 奖励: -120.0, Epsilon: 0.3
回合: 321/400, 奖励: -27.0, Epsilon: 0.3
回合: 322/400, 奖励: -21.0, Epsilon: 0.3
回合: 323/400, 奖励: -34.0, Epsilon: 0.3
回合: 324/400, 奖励: -17.0, Epsilon: 0.3
回合: 325/400, 奖励: -31.0, Epsilon: 0.3
回合: 326/400, 奖励: -21.0, Epsilon: 0.3
回合: 327/400, 奖励: -132.0, Epsilon: 0.3
回合: 328/400, 奖励: -128.0, Epsilon: 0.3
回合: 329/400, 奖励: -32.0, Epsilon: 0.3
回合: 330/400, 奖励: -19.0, Epsilon: 0.3
回合: 331/400, 奖励: -21.0, Epsilon: 0.3
回合: 332/400, 奖励: -31.0, Epsilon: 0.3
回合: 333/400, 奖励: -21.0, Epsilon: 0.3
回合: 334/400, 奖励: -33.0, Epsilon: 0.3
回合: 335/400, 奖励: -34.0, Epsilon: 0.3
回合: 336/400, 奖励: -127.0, Epsilon: 0.3
回合: 337/400, 奖励: -24.0, Epsilon: 0.3
回合: 338/400, 奖励: -21.0, Epsilon: 0.3
回合: 339/400, 奖励: -24.0, Epsilon: 0.3
回合: 340/400, 奖励: -19.0, Epsilon: 0.3
回合: 341/400, 奖励: -26.0, Epsilon: 0.3
回合: 342/400, 奖励: -22.0, Epsilon: 0.3
回合: 343/400, 奖励: -119.0, Epsilon: 0.3
回合: 344/400, 奖励: -20.0, Epsilon: 0.3
回合: 345/400, 奖励: -30.0, Epsilon: 0.3
回合: 346/400, 奖励: -22.0, Epsilon: 0.3
回合: 347/400, 奖励: -32.0, Epsilon: 0.3
回合: 348/400, 奖励: -28.0, Epsilon: 0.3
回合: 349/400, 奖励: -27.0, Epsilon: 0.3
回合: 350/400, 奖励: -24.0, Epsilon: 0.3
回合: 351/400, 奖励: -28.0, Epsilon: 0.3
回合: 352/400, 奖励: -29.0, Epsilon: 0.3
回合: 353/400, 奖励: -126.0, Epsilon: 0.3
回合: 354/400, 奖励: -125.0, Epsilon: 0.3
回合: 355/400, 奖励: -131.0, Epsilon: 0.3
回合: 356/400, 奖励: -22.0, Epsilon: 0.3
回合: 357/400, 奖励: -33.0, Epsilon: 0.3
回合: 358/400, 奖励: -26.0, Epsilon: 0.3
回合: 359/400, 奖励: -18.0, Epsilon: 0.3
回合: 360/400, 奖励: -22.0, Epsilon: 0.3
回合: 361/400, 奖励: -26.0, Epsilon: 0.3
回合: 362/400, 奖励: -18.0, Epsilon: 0.3
回合: 363/400, 奖励: -123.0, Epsilon: 0.3
回合: 364/400, 奖励: -27.0, Epsilon: 0.3
回合: 365/400, 奖励: -33.0, Epsilon: 0.3
回合: 366/400, 奖励: -29.0, Epsilon: 0.3
回合: 367/400, 奖励: -146.0, Epsilon: 0.3
回合: 368/400, 奖励: -19.0, Epsilon: 0.3
回合: 369/400, 奖励: -24.0, Epsilon: 0.3
回合: 370/400, 奖励: -18.0, Epsilon: 0.3
回合: 371/400, 奖励: -123.0, Epsilon: 0.3
回合: 372/400, 奖励: -22.0, Epsilon: 0.3

```
回合：373/400，奖励：-239.0，Epsilon：0.3
回合：374/400，奖励：-123.0，Epsilon：0.3
回合：375/400，奖励：-139.0，Epsilon：0.3
回合：376/400，奖励：-24.0，Epsilon：0.3
回合：377/400，奖励：-125.0，Epsilon：0.3
回合：378/400，奖励：-34.0，Epsilon：0.3
回合：379/400，奖励：-20.0，Epsilon：0.3
回合：380/400，奖励：-26.0，Epsilon：0.3
回合：381/400，奖励：-124.0，Epsilon：0.3
回合：382/400，奖励：-119.0，Epsilon：0.3
回合：383/400，奖励：-31.0，Epsilon：0.3
回合：384/400，奖励：-28.0，Epsilon：0.3
回合：385/400，奖励：-24.0，Epsilon：0.3
回合：386/400，奖励：-22.0，Epsilon：0.3
回合：387/400，奖励：-135.0，Epsilon：0.3
回合：388/400，奖励：-143.0，Epsilon：0.3
回合：389/400，奖励：-134.0，Epsilon：0.3
回合：390/400，奖励：-26.0，Epsilon：0.3
回合：391/400，奖励：-245.0，Epsilon：0.3
回合：392/400，奖励：-21.0，Epsilon：0.3
回合：393/400，奖励：-35.0，Epsilon：0.3
回合：394/400，奖励：-120.0，Epsilon：0.3
回合：395/400，奖励：-22.0，Epsilon：0.3
回合：396/400，奖励：-18.0，Epsilon：0.3
回合：397/400，奖励：-26.0，Epsilon：0.3
回合：398/400，奖励：-23.0，Epsilon：0.3
回合：399/400，奖励：-27.0，Epsilon：0.3
回合：400/400，奖励：-17.0，Epsilon：0.3
完成训练！
```

### 3.4.4 画出训练结果图

In [49]:
```python
plot_rewards(train_rewards, cfg, tag="train")
```




### 3.4.5 开始测试

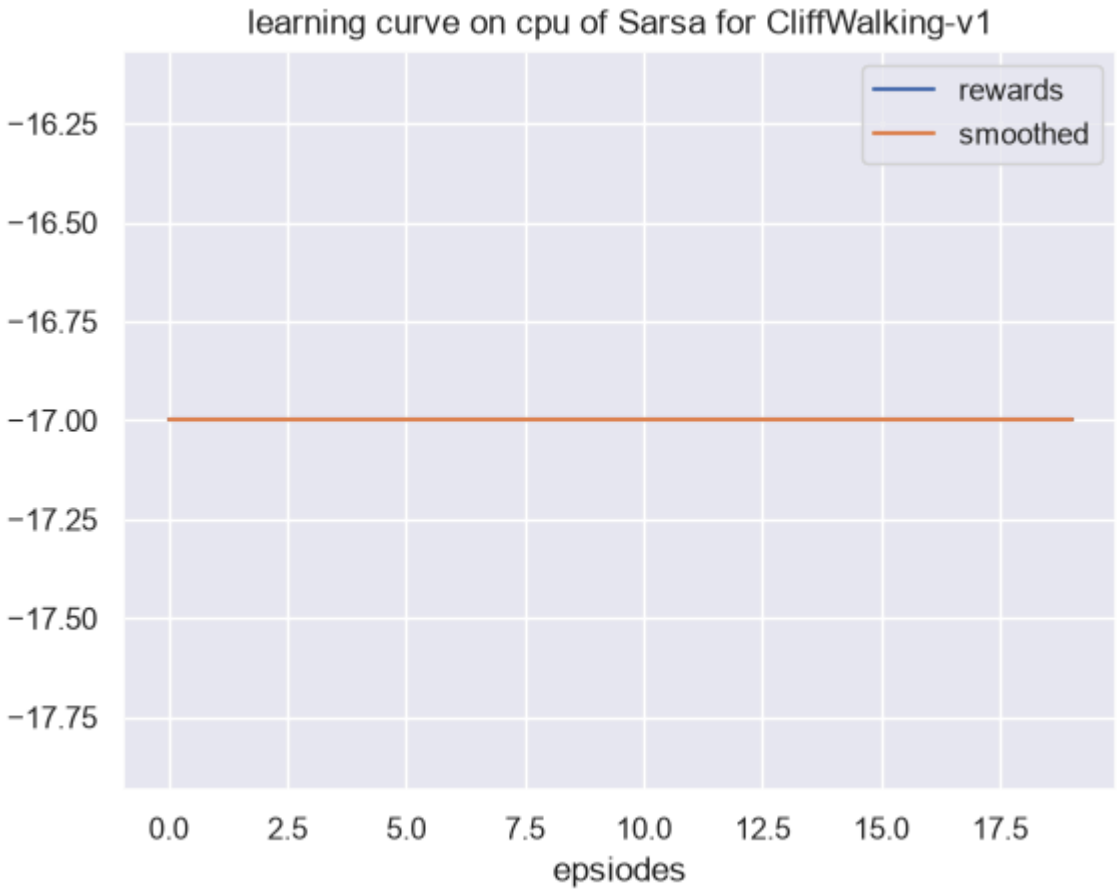
In [50]:
```python
print('开始测试！')
print(f'环境：{cfg.env_name}，算法：{cfg.algo_name}，设备：{cfg.device}')
test_rewards = []  # 记录所有回合的奖励
```

```
for i_ep in range(cfg.test_eps):
    ep_reward = 0  # 记录每个episode的reward
    state, _ = env.reset()  # 重置环境, 重新开一局（即开始新的一个回合）
    while True:
        action = agent.predict(state)  # 根据算法选择一个动作
        next_state, reward, terminated, truncated, _ = env.step(action)
        done = terminated or truncated
        state = next_state  # 更新状态
        ep_reward += reward
#         env.render() #windows 平台的同学和Linux有外界显示器的，可以尝试渲染
        if done:
            break
    test_rewards.append(ep_reward)
    print(f"回合数：{i_ep+1}/{cfg.test_eps}，奖励：{ep_reward:.1f}")
print('完成测试！')
```

```
开始测试！
环境：CliffWalking-v1，算法：Sarsa，设备：cpu
回合数：1/20，奖励：-17.0
回合数：2/20，奖励：-17.0
回合数：3/20，奖励：-17.0
回合数：4/20，奖励：-17.0
回合数：5/20，奖励：-17.0
回合数：6/20，奖励：-17.0
回合数：7/20，奖励：-17.0
回合数：8/20，奖励：-17.0
回合数：9/20，奖励：-17.0
回合数：10/20，奖励：-17.0
回合数：11/20，奖励：-17.0
回合数：12/20，奖励：-17.0
回合数：13/20，奖励：-17.0
回合数：14/20，奖励：-17.0
回合数：15/20，奖励：-17.0
回合数：16/20，奖励：-17.0
回合数：17/20，奖励：-17.0
回合数：18/20，奖励：-17.0
回合数：19/20，奖励：-17.0
回合数：20/20，奖励：-17.0
完成测试！
```

### 3.4.6 画出测试结果图

In [51]:
```
plot_rewards(test_rewards, cfg, tag="train")
```




## 3.5 Q-Learning

### 3.5.1 相关参数设定

In [52]:
```
parser = argparse.ArgumentParser(description="hyperparameters")
parser.add_argument('--algo_name',default='Q-learning',type=str,help="name of algorithm")
parser.add_argument('--env_name',default='CliffWalking-v1',type=str,help="name of environment")
parser.add_argument('--train_eps',default=400,type=int,help="episodes of training") # 训练的回合数
parser.add_argument('--test_eps',default=20,type=int,help="episodes of testing") # 测试的回合数
parser.add_argument('--gamma',default=0.90,type=float,help="discounted factor") # 折扣因子
parser.add_argument('--epsilon',default=0.3,type=float,help="initial value of epsilon") #  e-greedy策略中初始epsilon
parser.add_argument('--lr',default=0.1,type=float,help="learning rate")
parser.add_argument('--device',default='cpu',type=str,help="cpu or cuda")
parser.add_argument('--seed',default=26120258,type=int,help="random seed")
cfg = parser.parse_args([])
```

### 3.5.2 QLearning 主要代码框架

In [53]:
```
class QLearning(object):
    def __init__(self,n_states,
                 n_actions,cfg):
        self.n_actions = n_actions
        self.lr = cfg.lr  # 学习率
        self.gamma = cfg.gamma
        self.epsilon = cfg.epsilon
        self.sample_count = 0
        self.Q_table  = defaultdict(lambda: np.zeros(n_actions)) # 用嵌套字典存放状态->动作->状态-动作值（Q值）的映射，即Q表
    def sample(self, state):
        ''' 采样动作，训练时用
        '''
        self.sample_count += 1
        # e-greedy 策略
        if np.random.uniform(0, 1) > self.epsilon:
            # 选择Q(s,a)最大对应的动作，  通过查询Q表，选取在当前状态下Q值最大的动作
            action = np.argmax(self.Q_table[str(state)])
```

```
        else:
            # 随机选择动作
            action = np.random.choice(self.n_actions)


        return action
    def predict(self,state):
        ''' 预测或选择动作，测试时用
        '''
        action = np.argmax(self.Q_table[str(state)])
        return action
    def update(self, state, action, reward, next_state, done):
        '''
        基于采样得到的历史数据更新Q表
        '''
        Q_predict = self.Q_table[str(state)][action]  # 获得当前预测Q值
        if done: # 终止状态
            Q_target = reward
        else:
            # Q-learning是拿下一步中奖励最大的动作作为当前Q值的target进行更新
            Q_target = reward + self.gamma * np.max(self.Q_table[str(next_state)])


        self.Q_table[str(state)][action] += self.lr * (Q_target - Q_predict)
```

In [54]:
```
def env_agent_config(cfg,seed=1):
    '''创建环境和智能体
    Args:
        cfg ([type]): [description]
        seed (int, optional): 随机种子. Defaults to 1.
    Returns:
        env [type]: 环境
        agent : 智能体
    '''
    seed=cfg.seed
    np.random.seed(seed)

    env = gym.make(cfg.env_name)
    env = CliffWalkingWapper(env)
    env.reset(seed=seed) # 设置随机种子并初始化环境
    n_states = env.observation_space.n # 状态维度
    n_actions = env.action_space.n # 动作维度
    agent = QLearning(n_states,n_actions,cfg)
    return env,agent
```

In [55]:
```
env, agent = env_agent_config(cfg)
```

### 3.5.3 开始训练

In [56]:
```
print('开始训练！')
print(f'环境:{cfg.env_name}, 算法:{cfg.algo_name}, 设备:{cfg.device}')
train_rewards = []  # 记录奖励
for i_ep in range(cfg.train_eps):
    ep_reward = 0  # 记录每个回合的奖励
    state, _ = env.reset()  # 重置环境,即开始新的回合
    while True:
        action = agent.sample(state)  # 根据算法采样一个动作
        next_state, reward, terminated, truncated, _ = env.step(action)
        done = terminated or truncated
        agent.update(state, action, reward, next_state, terminated)  # Q学习算法更新
        state = next_state  # 更新状态
        ep_reward += reward
        if done:
            break
    train_rewards.append(ep_reward)
    print(f"回合：{i_ep+1}/{cfg.train_eps}，奖励：{ep_reward:.1f}，Epsilon：{agent.epsilon}")
print('完成训练！')
```

```
开始训练!
环境:CliffWalking-v1, 算法:Q-learning, 设备:cpu
回合：1/400，奖励：-562.0，Epsilon：0.3
回合：2/400，奖励：-5559.0，Epsilon：0.3
回合：3/400，奖励：-452.0，Epsilon：0.3
回合：4/400，奖励：-1720.0，Epsilon：0.3
```

回合: 5/400, 奖励: -145.0, Epsilon: 0.3
回合: 6/400, 奖励: -535.0, Epsilon: 0.3
回合: 7/400, 奖励: -1299.0, Epsilon: 0.3
回合: 8/400, 奖励: -742.0, Epsilon: 0.3
回合: 9/400, 奖励: -939.0, Epsilon: 0.3
回合: 10/400, 奖励: -494.0, Epsilon: 0.3
回合: 11/400, 奖励: -483.0, Epsilon: 0.3
回合: 12/400, 奖励: -467.0, Epsilon: 0.3
回合: 13/400, 奖励: -50.0, Epsilon: 0.3
回合: 14/400, 奖励: -496.0, Epsilon: 0.3
回合: 15/400, 奖励: -219.0, Epsilon: 0.3
回合: 16/400, 奖励: -57.0, Epsilon: 0.3
回合: 17/400, 奖励: -168.0, Epsilon: 0.3
回合: 18/400, 奖励: -571.0, Epsilon: 0.3
回合: 19/400, 奖励: -902.0, Epsilon: 0.3
回合: 20/400, 奖励: -471.0, Epsilon: 0.3
回合: 21/400, 奖励: -370.0, Epsilon: 0.3
回合: 22/400, 奖励: -169.0, Epsilon: 0.3
回合: 23/400, 奖励: -61.0, Epsilon: 0.3
回合: 24/400, 奖励: -69.0, Epsilon: 0.3
回合: 25/400, 奖励: -114.0, Epsilon: 0.3
回合: 26/400, 奖励: -784.0, Epsilon: 0.3
回合: 27/400, 奖励: -160.0, Epsilon: 0.3
回合: 28/400, 奖励: -387.0, Epsilon: 0.3
回合: 29/400, 奖励: -391.0, Epsilon: 0.3
回合: 30/400, 奖励: -66.0, Epsilon: 0.3
回合: 31/400, 奖励: -35.0, Epsilon: 0.3
回合: 32/400, 奖励: -915.0, Epsilon: 0.3
回合: 33/400, 奖励: -43.0, Epsilon: 0.3
回合: 34/400, 奖励: -159.0, Epsilon: 0.3
回合: 35/400, 奖励: -355.0, Epsilon: 0.3
回合: 36/400, 奖励: -910.0, Epsilon: 0.3
回合: 37/400, 奖励: -237.0, Epsilon: 0.3
回合: 38/400, 奖励: -187.0, Epsilon: 0.3
回合: 39/400, 奖励: -42.0, Epsilon: 0.3
回合: 40/400, 奖励: -134.0, Epsilon: 0.3
回合: 41/400, 奖励: -375.0, Epsilon: 0.3
回合: 42/400, 奖励: -187.0, Epsilon: 0.3
回合: 43/400, 奖励: -595.0, Epsilon: 0.3
回合: 44/400, 奖励: -28.0, Epsilon: 0.3
回合: 45/400, 奖励: -41.0, Epsilon: 0.3
回合: 46/400, 奖励: -53.0, Epsilon: 0.3
回合: 47/400, 奖励: -66.0, Epsilon: 0.3
回合: 48/400, 奖励: -309.0, Epsilon: 0.3
回合: 49/400, 奖励: -736.0, Epsilon: 0.3
回合: 50/400, 奖励: -1070.0, Epsilon: 0.3
回合: 51/400, 奖励: -60.0, Epsilon: 0.3
回合: 52/400, 奖励: -290.0, Epsilon: 0.3
回合: 53/400, 奖励: -375.0, Epsilon: 0.3
回合: 54/400, 奖励: -51.0, Epsilon: 0.3
回合: 55/400, 奖励: -147.0, Epsilon: 0.3
回合: 56/400, 奖励: -68.0, Epsilon: 0.3
回合: 57/400, 奖励: -27.0, Epsilon: 0.3
回合: 58/400, 奖励: -592.0, Epsilon: 0.3
回合: 59/400, 奖励: -21.0, Epsilon: 0.3
回合: 60/400, 奖励: -35.0, Epsilon: 0.3
回合: 61/400, 奖励: -265.0, Epsilon: 0.3
回合: 62/400, 奖励: -137.0, Epsilon: 0.3
回合: 63/400, 奖励: -272.0, Epsilon: 0.3
回合: 64/400, 奖励: -33.0, Epsilon: 0.3
回合: 65/400, 奖励: -21.0, Epsilon: 0.3
回合: 66/400, 奖励: -255.0, Epsilon: 0.3
回合: 67/400, 奖励: -161.0, Epsilon: 0.3
回合: 68/400, 奖励: -157.0, Epsilon: 0.3
回合: 69/400, 奖励: -21.0, Epsilon: 0.3
回合: 70/400, 奖励: -824.0, Epsilon: 0.3
回合: 71/400, 奖励: -64.0, Epsilon: 0.3
回合: 72/400, 奖励: -142.0, Epsilon: 0.3
回合: 73/400, 奖励: -32.0, Epsilon: 0.3
回合: 74/400, 奖励: -627.0, Epsilon: 0.3
回合: 75/400, 奖励: -27.0, Epsilon: 0.3
回合: 76/400, 奖励: -31.0, Epsilon: 0.3
回合: 77/400, 奖励: -138.0, Epsilon: 0.3
回合: 78/400, 奖励: -151.0, Epsilon: 0.3
回合: 79/400, 奖励: -619.0, Epsilon: 0.3
回合: 80/400, 奖励: -266.0, Epsilon: 0.3

回合: 81/400, 奖励: -834.0, Epsilon: 0.3
回合: 82/400, 奖励: -34.0, Epsilon: 0.3
回合: 83/400, 奖励: -126.0, Epsilon: 0.3
回合: 84/400, 奖励: -367.0, Epsilon: 0.3
回合: 85/400, 奖励: -130.0, Epsilon: 0.3
回合: 86/400, 奖励: -143.0, Epsilon: 0.3
回合: 87/400, 奖励: -36.0, Epsilon: 0.3
回合: 88/400, 奖励: -38.0, Epsilon: 0.3
回合: 89/400, 奖励: -46.0, Epsilon: 0.3
回合: 90/400, 奖励: -31.0, Epsilon: 0.3
回合: 91/400, 奖励: -391.0, Epsilon: 0.3
回合: 92/400, 奖励: -381.0, Epsilon: 0.3
回合: 93/400, 奖励: -129.0, Epsilon: 0.3
回合: 94/400, 奖励: -47.0, Epsilon: 0.3
回合: 95/400, 奖励: -273.0, Epsilon: 0.3
回合: 96/400, 奖励: -43.0, Epsilon: 0.3
回合: 97/400, 奖励: -44.0, Epsilon: 0.3
回合: 98/400, 奖励: -20.0, Epsilon: 0.3
回合: 99/400, 奖励: -38.0, Epsilon: 0.3
回合: 100/400, 奖励: -131.0, Epsilon: 0.3
回合: 101/400, 奖励: -36.0, Epsilon: 0.3
回合: 102/400, 奖励: -570.0, Epsilon: 0.3
回合: 103/400, 奖励: -259.0, Epsilon: 0.3
回合: 104/400, 奖励: -16.0, Epsilon: 0.3
回合: 105/400, 奖励: -285.0, Epsilon: 0.3
回合: 106/400, 奖励: -31.0, Epsilon: 0.3
回合: 107/400, 奖励: -135.0, Epsilon: 0.3
回合: 108/400, 奖励: -38.0, Epsilon: 0.3
回合: 109/400, 奖励: -26.0, Epsilon: 0.3
回合: 110/400, 奖励: -261.0, Epsilon: 0.3
回合: 111/400, 奖励: -492.0, Epsilon: 0.3
回合: 112/400, 奖励: -223.0, Epsilon: 0.3
回合: 113/400, 奖励: -127.0, Epsilon: 0.3
回合: 114/400, 奖励: -351.0, Epsilon: 0.3
回合: 115/400, 奖励: -28.0, Epsilon: 0.3
回合: 116/400, 奖励: -25.0, Epsilon: 0.3
回合: 117/400, 奖励: -23.0, Epsilon: 0.3
回合: 118/400, 奖励: -134.0, Epsilon: 0.3
回合: 119/400, 奖励: -34.0, Epsilon: 0.3
回合: 120/400, 奖励: -30.0, Epsilon: 0.3
回合: 121/400, 奖励: -23.0, Epsilon: 0.3
回合: 122/400, 奖励: -222.0, Epsilon: 0.3
回合: 123/400, 奖励: -21.0, Epsilon: 0.3
回合: 124/400, 奖励: -234.0, Epsilon: 0.3
回合: 125/400, 奖励: -38.0, Epsilon: 0.3
回合: 126/400, 奖励: -266.0, Epsilon: 0.3
回合: 127/400, 奖励: -139.0, Epsilon: 0.3
回合: 128/400, 奖励: -135.0, Epsilon: 0.3
回合: 129/400, 奖励: -24.0, Epsilon: 0.3
回合: 130/400, 奖励: -34.0, Epsilon: 0.3
回合: 131/400, 奖励: -26.0, Epsilon: 0.3
回合: 132/400, 奖励: -26.0, Epsilon: 0.3
回合: 133/400, 奖励: -250.0, Epsilon: 0.3
回合: 134/400, 奖励: -24.0, Epsilon: 0.3
回合: 135/400, 奖励: -22.0, Epsilon: 0.3
回合: 136/400, 奖励: -116.0, Epsilon: 0.3
回合: 137/400, 奖励: -142.0, Epsilon: 0.3
回合: 138/400, 奖励: -126.0, Epsilon: 0.3
回合: 139/400, 奖励: -146.0, Epsilon: 0.3
回合: 140/400, 奖励: -36.0, Epsilon: 0.3
回合: 141/400, 奖励: -130.0, Epsilon: 0.3
回合: 142/400, 奖励: -24.0, Epsilon: 0.3
回合: 143/400, 奖励: -485.0, Epsilon: 0.3
回合: 144/400, 奖励: -241.0, Epsilon: 0.3
回合: 145/400, 奖励: -16.0, Epsilon: 0.3
回合: 146/400, 奖励: -150.0, Epsilon: 0.3
回合: 147/400, 奖励: -140.0, Epsilon: 0.3
回合: 148/400, 奖励: -115.0, Epsilon: 0.3
回合: 149/400, 奖励: -30.0, Epsilon: 0.3
回合: 150/400, 奖励: -28.0, Epsilon: 0.3
回合: 151/400, 奖励: -26.0, Epsilon: 0.3
回合: 152/400, 奖励: -788.0, Epsilon: 0.3
回合: 153/400, 奖励: -19.0, Epsilon: 0.3
回合: 154/400, 奖励: -134.0, Epsilon: 0.3
回合: 155/400, 奖励: -341.0, Epsilon: 0.3
回合: 156/400, 奖励: -276.0, Epsilon: 0.3

回合: 157/400, 奖励: -36.0, Epsilon: 0.3
回合: 158/400, 奖励: -121.0, Epsilon: 0.3
回合: 159/400, 奖励: -22.0, Epsilon: 0.3
回合: 160/400, 奖励: -19.0, Epsilon: 0.3
回合: 161/400, 奖励: -17.0, Epsilon: 0.3
回合: 162/400, 奖励: -32.0, Epsilon: 0.3
回合: 163/400, 奖励: -32.0, Epsilon: 0.3
回合: 164/400, 奖励: -676.0, Epsilon: 0.3
回合: 165/400, 奖励: -32.0, Epsilon: 0.3
回合: 166/400, 奖励: -224.0, Epsilon: 0.3
回合: 167/400, 奖励: -39.0, Epsilon: 0.3
回合: 168/400, 奖励: -22.0, Epsilon: 0.3
回合: 169/400, 奖励: -149.0, Epsilon: 0.3
回合: 170/400, 奖励: -26.0, Epsilon: 0.3
回合: 171/400, 奖励: -17.0, Epsilon: 0.3
回合: 172/400, 奖励: -20.0, Epsilon: 0.3
回合: 173/400, 奖励: -15.0, Epsilon: 0.3
回合: 174/400, 奖励: -37.0, Epsilon: 0.3
回合: 175/400, 奖励: -356.0, Epsilon: 0.3
回合: 176/400, 奖励: -334.0, Epsilon: 0.3
回合: 177/400, 奖励: -23.0, Epsilon: 0.3
回合: 178/400, 奖励: -31.0, Epsilon: 0.3
回合: 179/400, 奖励: -142.0, Epsilon: 0.3
回合: 180/400, 奖励: -121.0, Epsilon: 0.3
回合: 181/400, 奖励: -20.0, Epsilon: 0.3
回合: 182/400, 奖励: -125.0, Epsilon: 0.3
回合: 183/400, 奖励: -22.0, Epsilon: 0.3
回合: 184/400, 奖励: -128.0, Epsilon: 0.3
回合: 185/400, 奖励: -20.0, Epsilon: 0.3
回合: 186/400, 奖励: -130.0, Epsilon: 0.3
回合: 187/400, 奖励: -127.0, Epsilon: 0.3
回合: 188/400, 奖励: -130.0, Epsilon: 0.3
回合: 189/400, 奖励: -15.0, Epsilon: 0.3
回合: 190/400, 奖励: -15.0, Epsilon: 0.3
回合: 191/400, 奖励: -123.0, Epsilon: 0.3
回合: 192/400, 奖励: -40.0, Epsilon: 0.3
回合: 193/400, 奖励: -35.0, Epsilon: 0.3
回合: 194/400, 奖励: -126.0, Epsilon: 0.3
回合: 195/400, 奖励: -260.0, Epsilon: 0.3
回合: 196/400, 奖励: -25.0, Epsilon: 0.3
回合: 197/400, 奖励: -448.0, Epsilon: 0.3
回合: 198/400, 奖励: -115.0, Epsilon: 0.3
回合: 199/400, 奖励: -243.0, Epsilon: 0.3
回合: 200/400, 奖励: -19.0, Epsilon: 0.3
回合: 201/400, 奖励: -251.0, Epsilon: 0.3
回合: 202/400, 奖励: -15.0, Epsilon: 0.3
回合: 203/400, 奖励: -575.0, Epsilon: 0.3
回合: 204/400, 奖励: -18.0, Epsilon: 0.3
回合: 205/400, 奖励: -125.0, Epsilon: 0.3
回合: 206/400, 奖励: -142.0, Epsilon: 0.3
回合: 207/400, 奖励: -13.0, Epsilon: 0.3
回合: 208/400, 奖励: -130.0, Epsilon: 0.3
回合: 209/400, 奖励: -128.0, Epsilon: 0.3
回合: 210/400, 奖励: -449.0, Epsilon: 0.3
回合: 211/400, 奖励: -19.0, Epsilon: 0.3
回合: 212/400, 奖励: -239.0, Epsilon: 0.3
回合: 213/400, 奖励: -117.0, Epsilon: 0.3
回合: 214/400, 奖励: -18.0, Epsilon: 0.3
回合: 215/400, 奖励: -17.0, Epsilon: 0.3
回合: 216/400, 奖励: -124.0, Epsilon: 0.3
回合: 217/400, 奖励: -20.0, Epsilon: 0.3
回合: 218/400, 奖励: -224.0, Epsilon: 0.3
回合: 219/400, 奖励: -627.0, Epsilon: 0.3
回合: 220/400, 奖励: -29.0, Epsilon: 0.3
回合: 221/400, 奖励: -13.0, Epsilon: 0.3
回合: 222/400, 奖励: -232.0, Epsilon: 0.3
回合: 223/400, 奖励: -19.0, Epsilon: 0.3
回合: 224/400, 奖励: -35.0, Epsilon: 0.3
回合: 225/400, 奖励: -24.0, Epsilon: 0.3
回合: 226/400, 奖励: -454.0, Epsilon: 0.3
回合: 227/400, 奖励: -117.0, Epsilon: 0.3
回合: 228/400, 奖励: -232.0, Epsilon: 0.3
回合: 229/400, 奖励: -13.0, Epsilon: 0.3
回合: 230/400, 奖励: -242.0, Epsilon: 0.3
回合: 231/400, 奖励: -117.0, Epsilon: 0.3
回合: 232/400, 奖励: -23.0, Epsilon: 0.3

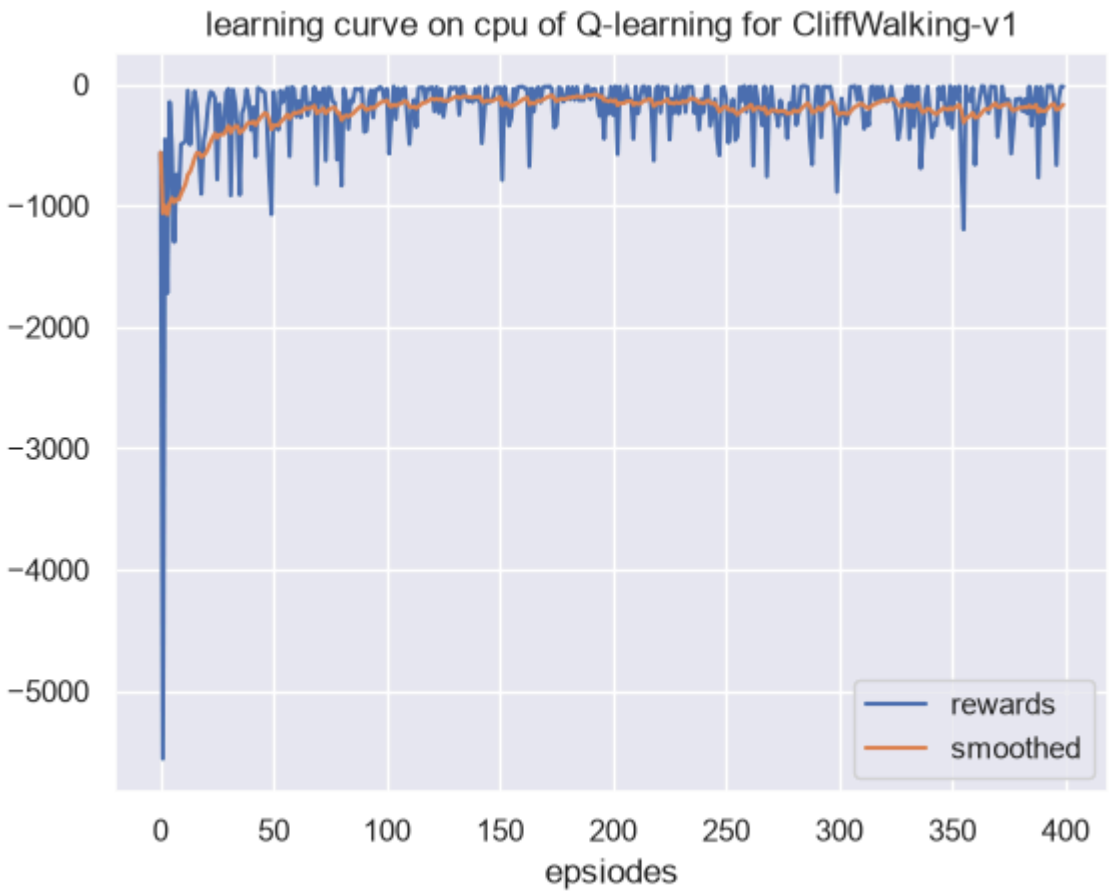
回合: 233/400, 奖励: -228.0, Epsilon: 0.3
回合: 234/400, 奖励: -17.0, Epsilon: 0.3
回合: 235/400, 奖励: -19.0, Epsilon: 0.3
回合: 236/400, 奖励: -20.0, Epsilon: 0.3
回合: 237/400, 奖励: -237.0, Epsilon: 0.3
回合: 238/400, 奖励: -135.0, Epsilon: 0.3
回合: 239/400, 奖励: -373.0, Epsilon: 0.3
回合: 240/400, 奖励: -125.0, Epsilon: 0.3
回合: 241/400, 奖励: -230.0, Epsilon: 0.3
回合: 242/400, 奖励: -20.0, Epsilon: 0.3
回合: 243/400, 奖励: -15.0, Epsilon: 0.3
回合: 244/400, 奖励: -342.0, Epsilon: 0.3
回合: 245/400, 奖励: -231.0, Epsilon: 0.3
回合: 246/400, 奖励: -122.0, Epsilon: 0.3
回合: 247/400, 奖励: -448.0, Epsilon: 0.3
回合: 248/400, 奖励: -584.0, Epsilon: 0.3
回合: 249/400, 奖励: -31.0, Epsilon: 0.3
回合: 250/400, 奖励: -20.0, Epsilon: 0.3
回合: 251/400, 奖励: -121.0, Epsilon: 0.3
回合: 252/400, 奖励: -480.0, Epsilon: 0.3
回合: 253/400, 奖励: -240.0, Epsilon: 0.3
回合: 254/400, 奖励: -123.0, Epsilon: 0.3
回合: 255/400, 奖励: -460.0, Epsilon: 0.3
回合: 256/400, 奖励: -428.0, Epsilon: 0.3
回合: 257/400, 奖励: -22.0, Epsilon: 0.3
回合: 258/400, 奖励: -133.0, Epsilon: 0.3
回合: 259/400, 奖励: -13.0, Epsilon: 0.3
回合: 260/400, 奖励: -227.0, Epsilon: 0.3
回合: 261/400, 奖励: -23.0, Epsilon: 0.3
回合: 262/400, 奖励: -17.0, Epsilon: 0.3
回合: 263/400, 奖励: -670.0, Epsilon: 0.3
回合: 264/400, 奖励: -16.0, Epsilon: 0.3
回合: 265/400, 奖励: -134.0, Epsilon: 0.3
回合: 266/400, 奖励: -218.0, Epsilon: 0.3
回合: 267/400, 奖励: -338.0, Epsilon: 0.3
回合: 268/400, 奖励: -17.0, Epsilon: 0.3
回合: 269/400, 奖励: -759.0, Epsilon: 0.3
回合: 270/400, 奖励: -122.0, Epsilon: 0.3
回合: 271/400, 奖励: -19.0, Epsilon: 0.3
回合: 272/400, 奖励: -224.0, Epsilon: 0.3
回合: 273/400, 奖励: -222.0, Epsilon: 0.3
回合: 274/400, 奖励: -344.0, Epsilon: 0.3
回合: 275/400, 奖励: -131.0, Epsilon: 0.3
回合: 276/400, 奖励: -244.0, Epsilon: 0.3
回合: 277/400, 奖励: -227.0, Epsilon: 0.3
回合: 278/400, 奖励: -444.0, Epsilon: 0.3
回合: 279/400, 奖励: -155.0, Epsilon: 0.3
回合: 280/400, 奖励: -222.0, Epsilon: 0.3
回合: 281/400, 奖励: -17.0, Epsilon: 0.3
回合: 282/400, 奖励: -334.0, Epsilon: 0.3
回合: 283/400, 奖励: -236.0, Epsilon: 0.3
回合: 284/400, 奖励: -21.0, Epsilon: 0.3
回合: 285/400, 奖励: -13.0, Epsilon: 0.3
回合: 286/400, 奖励: -15.0, Epsilon: 0.3
回合: 287/400, 奖励: -21.0, Epsilon: 0.3
回合: 288/400, 奖励: -435.0, Epsilon: 0.3
回合: 289/400, 奖励: -660.0, Epsilon: 0.3
回合: 290/400, 奖励: -223.0, Epsilon: 0.3
回合: 291/400, 奖励: -20.0, Epsilon: 0.3
回合: 292/400, 奖励: -17.0, Epsilon: 0.3
回合: 293/400, 奖励: -435.0, Epsilon: 0.3
回合: 294/400, 奖励: -19.0, Epsilon: 0.3
回合: 295/400, 奖励: -18.0, Epsilon: 0.3
回合: 296/400, 奖励: -26.0, Epsilon: 0.3
回合: 297/400, 奖励: -17.0, Epsilon: 0.3
回合: 298/400, 奖励: -129.0, Epsilon: 0.3
回合: 299/400, 奖励: -331.0, Epsilon: 0.3
回合: 300/400, 奖励: -886.0, Epsilon: 0.3
回合: 301/400, 奖励: -358.0, Epsilon: 0.3
回合: 302/400, 奖励: -116.0, Epsilon: 0.3
回合: 303/400, 奖励: -229.0, Epsilon: 0.3
回合: 304/400, 奖励: -325.0, Epsilon: 0.3
回合: 305/400, 奖励: -248.0, Epsilon: 0.3
回合: 306/400, 奖励: -19.0, Epsilon: 0.3
回合: 307/400, 奖励: -19.0, Epsilon: 0.3
回合: 308/400, 奖励: -13.0, Epsilon: 0.3

回合: 309/400, 奖励: -130.0, Epsilon: 0.3
回合: 310/400, 奖励: -19.0, Epsilon: 0.3
回合: 311/400, 奖励: -128.0, Epsilon: 0.3
回合: 312/400, 奖励: -366.0, Epsilon: 0.3
回合: 313/400, 奖励: -240.0, Epsilon: 0.3
回合: 314/400, 奖励: -337.0, Epsilon: 0.3
回合: 315/400, 奖励: -24.0, Epsilon: 0.3
回合: 316/400, 奖励: -15.0, Epsilon: 0.3
回合: 317/400, 奖励: -131.0, Epsilon: 0.3
回合: 318/400, 奖励: -19.0, Epsilon: 0.3
回合: 319/400, 奖励: -127.0, Epsilon: 0.3
回合: 320/400, 奖励: -17.0, Epsilon: 0.3
回合: 321/400, 奖励: -118.0, Epsilon: 0.3
回合: 322/400, 奖励: -144.0, Epsilon: 0.3
回合: 323/400, 奖励: -125.0, Epsilon: 0.3
回合: 324/400, 奖励: -17.0, Epsilon: 0.3
回合: 325/400, 奖励: -131.0, Epsilon: 0.3
回合: 326/400, 奖励: -220.0, Epsilon: 0.3
回合: 327/400, 奖励: -452.0, Epsilon: 0.3
回合: 328/400, 奖励: -347.0, Epsilon: 0.3
回合: 329/400, 奖励: -123.0, Epsilon: 0.3
回合: 330/400, 奖励: -136.0, Epsilon: 0.3
回合: 331/400, 奖励: -15.0, Epsilon: 0.3
回合: 332/400, 奖励: -448.0, Epsilon: 0.3
回合: 333/400, 奖励: -15.0, Epsilon: 0.3
回合: 334/400, 奖励: -348.0, Epsilon: 0.3
回合: 335/400, 奖励: -24.0, Epsilon: 0.3
回合: 336/400, 奖励: -19.0, Epsilon: 0.3
回合: 337/400, 奖励: -691.0, Epsilon: 0.3
回合: 338/400, 奖励: -427.0, Epsilon: 0.3
回合: 339/400, 奖励: -123.0, Epsilon: 0.3
回合: 340/400, 奖励: -17.0, Epsilon: 0.3
回合: 341/400, 奖励: -227.0, Epsilon: 0.3
回合: 342/400, 奖励: -436.0, Epsilon: 0.3
回合: 343/400, 奖励: -327.0, Epsilon: 0.3
回合: 344/400, 奖励: -337.0, Epsilon: 0.3
回合: 345/400, 奖励: -23.0, Epsilon: 0.3
回合: 346/400, 奖励: -120.0, Epsilon: 0.3
回合: 347/400, 奖励: -17.0, Epsilon: 0.3
回合: 348/400, 奖励: -238.0, Epsilon: 0.3
回合: 349/400, 奖励: -330.0, Epsilon: 0.3
回合: 350/400, 奖励: -13.0, Epsilon: 0.3
回合: 351/400, 奖励: -360.0, Epsilon: 0.3
回合: 352/400, 奖励: -22.0, Epsilon: 0.3
回合: 353/400, 奖励: -115.0, Epsilon: 0.3
回合: 354/400, 奖励: -15.0, Epsilon: 0.3
回合: 355/400, 奖励: -674.0, Epsilon: 0.3
回合: 356/400, 奖励: -1195.0, Epsilon: 0.3
回合: 357/400, 奖励: -17.0, Epsilon: 0.3
回合: 358/400, 奖励: -122.0, Epsilon: 0.3
回合: 359/400, 奖励: -138.0, Epsilon: 0.3
回合: 360/400, 奖励: -28.0, Epsilon: 0.3
回合: 361/400, 奖励: -662.0, Epsilon: 0.3
回合: 362/400, 奖励: -228.0, Epsilon: 0.3
回合: 363/400, 奖励: -121.0, Epsilon: 0.3
回合: 364/400, 奖励: -13.0, Epsilon: 0.3
回合: 365/400, 奖励: -17.0, Epsilon: 0.3
回合: 366/400, 奖励: -127.0, Epsilon: 0.3
回合: 367/400, 奖励: -235.0, Epsilon: 0.3
回合: 368/400, 奖励: -16.0, Epsilon: 0.3
回合: 369/400, 奖励: -21.0, Epsilon: 0.3
回合: 370/400, 奖励: -19.0, Epsilon: 0.3
回合: 371/400, 奖励: -432.0, Epsilon: 0.3
回合: 372/400, 奖励: -241.0, Epsilon: 0.3
回合: 373/400, 奖励: -17.0, Epsilon: 0.3
回合: 374/400, 奖励: -135.0, Epsilon: 0.3
回合: 375/400, 奖励: -125.0, Epsilon: 0.3
回合: 376/400, 奖励: -125.0, Epsilon: 0.3
回合: 377/400, 奖励: -570.0, Epsilon: 0.3
回合: 378/400, 奖励: -347.0, Epsilon: 0.3
回合: 379/400, 奖励: -123.0, Epsilon: 0.3
回合: 380/400, 奖励: -121.0, Epsilon: 0.3
回合: 381/400, 奖励: -115.0, Epsilon: 0.3
回合: 382/400, 奖励: -221.0, Epsilon: 0.3
回合: 383/400, 奖励: -121.0, Epsilon: 0.3
回合: 384/400, 奖励: -239.0, Epsilon: 0.3

```
回合：385/400，奖励：-17.0，Epsilon：0.3
回合：386/400，奖励：-341.0，Epsilon：0.3
回合：387/400，奖励：-123.0，Epsilon：0.3
回合：388/400，奖励：-21.0，Epsilon：0.3
回合：389/400，奖励：-767.0，Epsilon：0.3
回合：390/400，奖励：-22.0，Epsilon：0.3
回合：391/400，奖励：-332.0，Epsilon：0.3
回合：392/400，奖励：-232.0，Epsilon：0.3
回合：393/400，奖励：-13.0，Epsilon：0.3
回合：394/400，奖励：-15.0，Epsilon：0.3
回合：395/400，奖励：-13.0，Epsilon：0.3
回合：396/400，奖励：-132.0，Epsilon：0.3
回合：397/400，奖励：-664.0，Epsilon：0.3
回合：398/400，奖励：-116.0，Epsilon：0.3
回合：399/400，奖励：-17.0，Epsilon：0.3
回合：400/400，奖励：-17.0，Epsilon：0.3
完成训练！
```

### 3.5.4 画出训练结果

In [57]:
```python
plot_rewards(train_rewards, cfg, tag="train")
```




### 3.5.5 开始测试

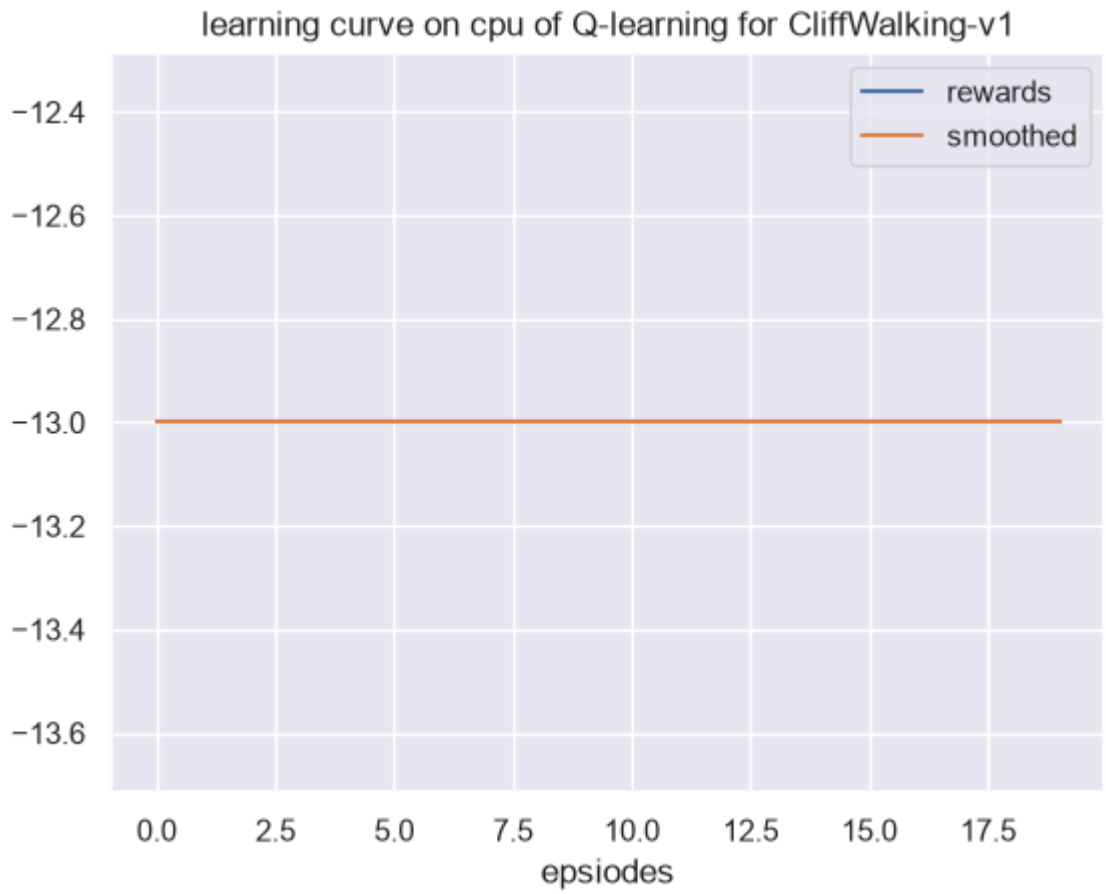
In [58]:
```python
print('开始测试！')
print(f'环境：{cfg.env_name}，算法：{cfg.algo_name}，设备：{cfg.device}')
test_rewards = []  # 记录所有回合的奖励
for i_ep in range(cfg.test_eps):
    ep_reward = 0  # 记录每个episode的reward
    state, _ = env.reset()  # 重置环境，重新开一局（即开始新的一个回合）
    print(i_ep)
    while True:
        action = agent.predict(state)  # 根据算法选择一个动作
        next_state, reward, terminated, truncated, _ = env.step(action)
        done = terminated or truncated
#         env.render() #windows 平台的同学和Linux有外界显示器的，可以尝试渲染
        state = next_state  # 更新状态
        ep_reward += reward
        if done:
```

```
            break
    test_rewards.append(ep_reward)
    print(f"回合数：{i_ep+1}/{cfg.test_eps}，奖励：{ep_reward:.1f}")
print('完成测试！')
```

```
开始测试！
环境：CliffWalking-v1，算法：Q-learning，设备：cpu
0
回合数：1/20，奖励：-13.0
1
回合数：2/20，奖励：-13.0
2
回合数：3/20，奖励：-13.0
3
回合数：4/20，奖励：-13.0
4
回合数：5/20，奖励：-13.0
5
回合数：6/20，奖励：-13.0
6
回合数：7/20，奖励：-13.0
7
回合数：8/20，奖励：-13.0
8
回合数：9/20，奖励：-13.0
9
回合数：10/20，奖励：-13.0
10
回合数：11/20，奖励：-13.0
11
回合数：12/20，奖励：-13.0
12
回合数：13/20，奖励：-13.0
13
回合数：14/20，奖励：-13.0
14
回合数：15/20，奖励：-13.0
15
回合数：16/20，奖励：-13.0
16
回合数：17/20，奖励：-13.0
17
回合数：18/20，奖励：-13.0
18
回合数：19/20，奖励：-13.0
19
回合数：20/20，奖励：-13.0
完成测试！
```

### 3.5.6 画出测试结果

In [59]:
```
plot_rewards(test_rewards, cfg, tag="test")  # 画出结果
```


learning curve on cpu of Q-learning for CliffWalking-v1
rewards
smoothed
−12.4
−12.6
−12.8
−13.0
−13.2
−13.4
−13.6
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
epsiodes

## 4. 问题

**Q1&2：** Q-learning 和 SARSA的区别？从训练结果中你有什么样的发现？为什么训练结果会有这些不同？为什么在测试阶段的最终结果有所差异?

SARSA 是 on-policy 算法，使用当前行为策略实际选出的下一个动作 $a'$：

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[ r + \gamma Q(s',a') - Q(s,a) \right]$$

实验中，$a'$ 由$\epsilon$-greedy 策略采样，因此更新过程会考虑随机探索可能带来的影响。

Q-learning 是 off-policy 算法。使用下一状态所有动作中的最大 $Q$ 值进行更新：

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[ r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

更新目标直接按照下一步选择最优动作计算，不考虑实际探索带来的风险。

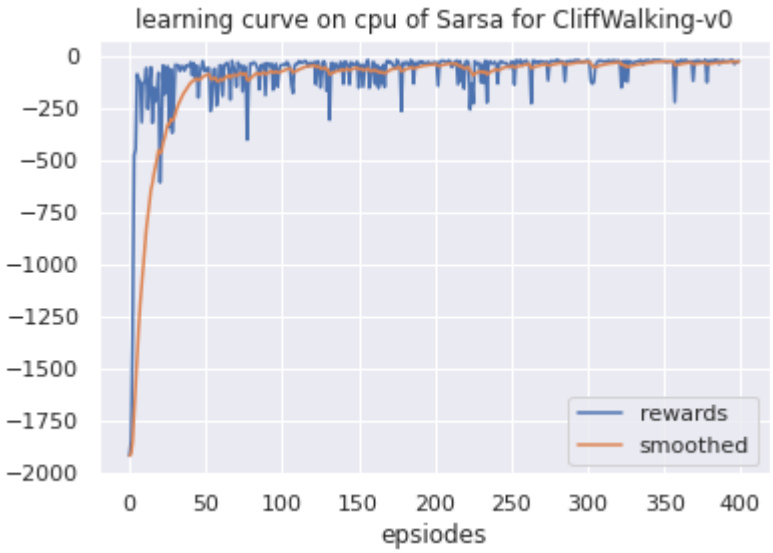
对比两个实验的曲线可以注意到：

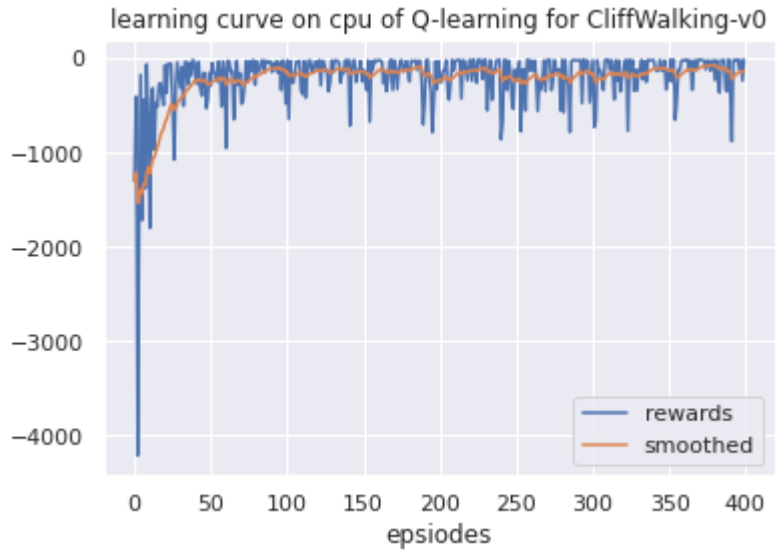
- SARSA在前 50 个回合内奖励迅速上升并收敛。到了训练中后期（如 200~400 回合），大多数单回合奖励稳定在 $-17.0$ 到 $-35.0$ 之间，平滑曲线（smoothed）贴近 0 轴下方（约 $-30$ 左右），偶发掉入悬崖的次数较少（下探尖峰多在 $-120$ 到 $-250$ 之间）。
- Q-learning虽然收敛速度同样很快，但在整个训练周期内，单回合奖励（蓝线 rewards）的震荡幅度显著大于 SARSA，频繁出现跌落至 $-500$ 甚至 $-1000$ 以下 的剧烈负奖励尖峰，导致其平滑奖励曲线（smoothed）整体低于 SARSA（在 $-100$ 到 $-200$ 附近波动）。

训练阶段，SARSA 的回报总体更高，后期波动也较小；Q-learning 仍然频繁出现较大的负回报。这与训练时固定使用 $\epsilon = 0.3$ 有关：即使已经学到较好的策略，智能体仍会持续探索。

SARSA 的更新考虑了探索动作的后果。靠近悬崖行走时，随机动作可能导致坠崖并获得 $-100$ 的奖励，因此 SARSA 倾向学习远离悬崖、步数稍多的安全路线。Q-learning 的更新则按照未来选择最优动作计算，倾向学习贴近悬崖的最短路线；但实际训练仍有随机探索，因此更容易坠崖，导致训练回报较低、波动较大。

测试阶段，两种算法都调用 `predict()`，直接采取确定性的纯贪心策略，直接选择 $Q$ 值最大的动作，不再随机探索。Q-learning 因而能够沿最短路线用 13 步到达终点，获得 $-13$ 的回报；本次 SARSA 学到的贪心路线需要 17 步，回报为 $-17$。测试时取消探索不会重新学习 $Q$ 值，因此 SARSA 仍然保留训练过程中形成的安全绕行策略。






**Q3：** $\epsilon$的大小对于实验结果的影响？你觉得如何调整较为合适？

$\epsilon$ 控制 $\epsilon$-greedy 策略中的探索程度。$\epsilon$ 较大时，智能体能够尝试更多状态和动作，有利于早期探索，但也会增加无效移动和坠崖的次数，使训练回报降低、波动增大。$\epsilon$ 较小时，智能体更多地利用已经学到的策略，通常有利于后期稳定表现，但如果训练初期就设置得过小，可能因探索不足而无法找到更好的路线。

$\epsilon$ 对两种算法的影响也有所不同。SARSA 使用实际采样的下一动作更新，因此 $\epsilon$ 会影响它所学习的策略：探索越频繁，悬崖附近的风险越大，通常越倾向于安全绕行。Q-learning 的更新目标始终使用下一状态的最大 $Q$ 值，但 $\epsilon$ 仍会影响训练数据的采集和实际训练回报。本实验固定使用 $\epsilon = 0.3$，因此训练后期依然存在较多随机探索，尤其容易使沿悬崖行走的 Q-learning 智能体坠崖。

较合适的方法是在训练初期保留较多探索，随后逐步减小 $\epsilon$。例如，可以尝试按回合进行衰减：

$$\epsilon_k = \max\left(0.01,\ 0.3 \times 0.99^{k}\right)$$

其中 $k$ 从 0 开始表示训练回合编号。这样初期可以充分探索，后期则更多地利用已有经验，同时保留少量探索机会。这只是可尝试的设置，具体衰减速度需要结合训练回报、测试路径和多个随机种子的结果进行比较。

**Q4：** 折扣因子的大小是否会对训练结果产生影响？为什么会出现这种影响？

会。折扣因子 $\gamma$ 决定智能体对未来奖励的重视程度，因此会影响 SARSA 和 Q-learning 的 $Q$ 值更新及学习结果。

当 $\gamma$ 较小时，智能体更关注即时奖励。但悬崖寻路中大多数正常动作的奖励都是 $-1$，过小的 $\gamma$ 会使智能体难以区分动作的长期价值，也难以充分考虑之后的坠崖风险。当 $\gamma$ 较大时，智能体更重视未来的累计奖励，有利于考虑完整路径的代价，但也可能放大后续 $Q$ 值估计误差的影响，并非越大越好。

本实验使用 $\gamma = 0.9$。调整它可能影响训练速度、回报波动和最终策略，但不一定改变最优路线。可以在其他参数相同的条件下，对比不同 $\gamma$ 的训练与测试结果。

## 5. 提交形式

- 提交notebook**原始文件**， 即以.ipynb为结尾的文件
- 本次实验notebook的**pdf**
- pdf转换方法：
    1. 在当前页面浏览器右上角选择“打印...”
    2. 目标打印机选择“另存为PDF”，布局选择“纵向”。然后查看预览效果，主要查看是否有代码内容显示不全，若无，则按“保存”即可，否则，继续选择下面的“缩放”，直到预览的结果满意为止，最后点击“保存”即可。